

Monte Carlo II: Tempi di convergenza e di autocorrelazione

Un'osservazione terminologica: sono accorto che il termine “dinamica di Glauber” va usato in certe referenze come ho usato io, in altre per la dinamica *heat bath* con lo stesso ρ_0 . Generalmente il comportamento dei due è abbastanza simile.

1 Heat bath di nuovo

La versione del metodo *heat bath* (che si chiama anche, a.e. in Friedli e Velenik sezione 3.10.3, *Gibbs sampler*) che ho presentato l'ultima volta era solo un caso particolare; qua darò una definizione più generale, anche se può essere generalizzato ancora di più (ad esempio a modelli con spazi continui di configurazioni, come il modello di Heisenberg che vedremo più avanti nel corso).

Consideriamo un insieme finito Ω ed una misura μ su Ω ; ed in più, una funzione $c(\omega, X)$ che prende valori in $[0, 1]$ per $\omega \in \Omega$, $X \subset \Omega$ con questi proprietà:

- $c(\omega, X) = 0$ se $\omega \notin X$ (compreso $X = \emptyset$)
- $\sum_{X \subset \Omega} c(\omega, X) = 1$ per ogni $\omega \in \Omega$
- $c(\omega, X) = c(\omega', X)$ per ogni $\omega, \omega' \in \Omega$, $X \subset \Omega$

che quindi definisce una regola probabilistica da scegliere, dato $\omega \in \Omega$, un insieme $\omega \in X \subset \Omega$, con una certa proprietà di simmetria nei probabilità. Ad esempio, la regola data nell'appunto precedente corrisponde a

$$c(\omega, X) = \begin{cases} |\Lambda|^{-1}, & X = \{\omega, \omega^x\} \text{ per qualche } x \in \Lambda \\ 0, & \text{altrimenti} \end{cases} \quad (1)$$

ovvero la regola di scegliere uniformemente fra gli insiemi $\{\omega, \omega^x\}$. La dinamica di bagno di calore consiste in scegliere un insieme X con probabilità $c(\omega, X)$ e puoi scegliere una nuova configurazione ν fra quelli in X con probabilità proporzionale a $\mu(\nu)$; quindi la probabilità di transizione è dato per

$$\rho(\omega, \nu) = \sum_{\substack{X \subset \Omega \\ X \ni \nu}} c(\omega, X) \frac{\mu(\nu)}{\sum_{\xi \in X} \mu(\xi)} = \sum_{\substack{X \subset \Omega \\ X \ni \nu}} c(\omega, X) \mu(\nu|X). \quad (2)$$

Esercizio 1. Verificare che, dato le proprietà richieste di c , μ soddisfa equilibrio in dettaglio per questo ρ .

Ci sono ovviamente tante scelte di c e quindi di dinamica, per ottenere qualcosa utile bisogna trovare uno che produce insiemi X per i quali la probabilità condizionale $\mu(\nu|X)$ è facile da calcolare, e che la dinamica è ergodica.

2 Rallentamento critico

I prodotti più importanti di simulazioni Monte Carlo sono medie temporali di osservabili che, per tempi sufficientemente lunghi, dovranno essere vicini alle medie rispetto alle misure stazionarie (che, per costruzione, sono misure di Gibbs del sistema sotto studio). Una complicazione molto importante è che il “tempo lungo” dipende delle circostanze; in Figura 1, si vede un esempio tipico del comportamento a tempi brevi per temperature più alte della temperatura critica: la magnetizzazione media converge esponenzialmente (nota che la scala verticale è logaritmica). L'asse orizzontale è stato riscalato a t/L^2 , e le curve sono piuttosto simili, confermando che il tempo di convergenza è proporzionale al volume L^2 del sistema, però la convergenza diviene più lenta il più che si avvicini il valore critico $\beta_c = \tanh^{-1}(\sqrt{2}-1) = \frac{1}{2} \log(1+\sqrt{2}) = 0.4407..$ (infatti diverge se si considera anche il limite di un sistema infinita, ma questo è difficile ad esibire con figure finite). Questo comportamento (*critical slowing down*, rallentamento critico) si manifesta anche per altri nozioni della scala di tempo della simulazione, e si verifica molto generalmente in sistemi con dinamica locale




Figura 1: Il comportamento iniziale per la dinamica di Glauber in 2D con $h = 0$, $\bar{\omega} \equiv 1$ e diversi valori di β e L

nella vicinanza di un punto critico. È quindi interessante in se stesso, ma visto che il punto critico è proprio la zona più interessante dal punto di vista della meccanica statistica, è un ostacolo importante; vi consiglio di provare un po' di fare simulazione alla temperatura critica in tagli diversi del sistema; già per sistemi non proprio grandi i tempi di convergenza possono essere sostanziale.

Si può chiaramente rendere la simulazione più efficiente; usando un linguaggio di più basso livello come C, ancora di più usando un algoritmo parallelizzato (ci sono varianti della dinamica di Glauber che si presta moltissimo ad esecuzione parallela o GPGPU), e ci sono altri modelli in cui questi sono gli unici possibilità, ma spesso si può fare meglio con un algoritmo più adatto; vediamo due di questi.

3 Modello di cluster aleatorio e la dinamica di Swendsen e Wang

Visto che $\sigma_i, \sigma_j = \pm 1$, abbiamo $e^{\beta \sigma_i \sigma_j} = e^{\pm \beta}$ e, controllando i vari possibilità, abbiamo

$$e^{\beta \sigma_i \sigma_j} = e^{-\beta} + (e^{\beta} - e^{-\beta}) \mathbb{1}_{\{\sigma_i = \sigma_j\}} = e^{\beta} \{(1 - p_{\beta}) + p_{\beta} \mathbb{1}_{\{\sigma_i = \sigma_j\}}\}, \quad (3)$$

dove ho definito $p_{\beta} := 1 - e^{-2\beta}$, che sarà un numero fra 0 e 1, visto che $\beta \geq 0$. Possiamo allora espandere come nella rappresentazione ad alta temperatura (Esercizio 3.22 di [FV]) per ottenere

$$\prod_{\{i,j\} \in \mathcal{E}_{\Lambda}} e^{\beta \sigma_i \sigma_j} = e^{\beta |\mathcal{E}_{\Lambda}|} \sum_{E \subset \mathcal{E}_{\Lambda}} p_{\beta}^{|E|} (1 - p_{\beta})^{|\mathcal{E}_{\Lambda} \setminus E|} \prod_{\{i,j\} \in E} \mathbb{1}_{\{\sigma_i = \sigma_j\}}, \quad (4)$$

e, di conseguenza, la misura di Gibbs senza campo magnetico può essere scritto come

$$\mu_{\Lambda;\beta,0}^{\emptyset}(\omega) = \frac{1}{Z_{\Lambda;\beta,0}^{\emptyset}} e^{\beta |\mathcal{E}_{\Lambda}|} \sum_{E \subset \mathcal{E}_{\Lambda}} p_{\beta}^{|E|} (1 - p_{\beta})^{|\mathcal{E}_{\Lambda} \setminus E|} \prod_{\{i,j\} \in E} \mathbb{1}_{\{\sigma_i = \sigma_j\}}(\omega). \quad (5)$$

Allora, se consideriamo un spazio di probabilità fatto delle coppie

$$\Phi := \left\{ (\omega, E) \mid \omega \in \Omega_{\Lambda}^{\emptyset}, E \subset \mathcal{E}_{\Lambda}, \sigma_i(\omega) = \sigma_j(\omega), \forall \{i, j\} \in E \right\} \quad (6)$$

(cioè quello che corrispondono ai termini non zero in (5)) con misura

$$\pi_{\Lambda;\beta,0}^{\emptyset}(\omega, E) = \frac{1}{Z_{\Lambda;\beta,0}^{\emptyset}} e^{\beta |\mathcal{E}_{\Lambda}|} \sum_{E \subset \mathcal{E}_{\Lambda}} p_{\beta}^{|E|} (1 - p_{\beta})^{|\mathcal{E}_{\Lambda} \setminus E|}, \quad (7)$$

allora la distribuzione marginale di ω è sempre $\mu_{\Lambda;\beta,0}^{\emptyset}(\omega)$, cioè

$$\sum_{\substack{E \subset \mathcal{E}_{\Lambda}: \\ \Phi(\omega, E)}} \pi_{\Lambda;\beta,0}^{\emptyset}(\omega, E) = \mu_{\Lambda;\beta,0}^{\emptyset}(\omega) \quad (8)$$

in quanto la limitazione dell'insieme di sommazione riproduce proprio il prodotto di funzioni indicatrici in eq. (5). La distribuzione marginale di E è il cosiddetto *FK-cluster* o *FK-percolation* process (introdotto anche in [FV] Sezione 3.10.6 per altre condizioni di bordo); in altre parole la misura π è un accoppiamento (*coupling*) del modello Ising e questo nuovo processo.

I algoritmi che useremo per simulare π sono più comodo a definire in due passi.

Esercizio 2. Verificare che se una misura è stazionaria per ambedue le probabilità di transizione ρ e ϱ , lo è anche per

$$(\rho\varrho)(\omega, \nu) := \sum_{\xi \in \Omega} \rho(\omega, \xi) \varrho(\xi, \nu). \quad (9)$$

Per cominciare consideriamo la dinamica ρ di bagno di calore in cui, dato (ω, E) scegliamo con probabilità uno l'insieme di tutti configurazioni permessi con lo stesso ω ; altrimenti detto, definendo $\bar{E}_\omega := \{\{i, j\} \in \mathcal{E}_\Lambda \mid \sigma_i(\omega) = \sigma_j(\omega)\}$, scegliamo E' con probabilità

$$\begin{cases} p_\beta^{|E'|} (1 - p_\beta)^{|\bar{E}_\omega|} = \prod_{\{i, j\} \in E'} p_\beta \prod_{\{i, j\} \in \bar{E}_\omega \setminus E'} (1 - p_\beta), & E' \subset \bar{E}_\omega \\ 0, & E' \not\subset \bar{E}_\omega \end{cases} \quad (10)$$

e questo è una misura di Bernoulli; ovvero, produciamo E' decidendo indipendentemente per ogni $\{i, j\} \in \mathcal{E}_\Lambda$ con $\sigma_i(\omega) = \sigma_j(\omega)$ di includerlo con probabilità p_β .

Poi, consideriamo un altro bagno di calore ϱ , dove invece teniamo fissato E' e consideriamo tutti gli ω' compatibili con E' , cioè che sono costanti su ogni componente di Λ collegato per E' (chiamato anche cluster). Adesso la misura condizionale $\pi(\omega' | X)$ è semplicemente la misura uniforme.

Riassumendo, la dinamica $\rho\varrho$, per quale π è sempre stazionaria, si può realizzare così:

1. Generare un insieme aleatorio E' considerando uno per uno gli $\{i, j\} \in \mathcal{E}_\Lambda$ con $\sigma_i(\omega) = \sigma_j(\omega)$ e indipendentemente includendoli con probabilità p_β
2. Trovare l'insieme $\mathcal{C}(E')$ componenti di Λ connessi da E'
3. Per ogni $C \in \mathcal{C}(E')$, scegliere indipendentemente ed uniformemente un valore da $\{+1, -1\}$ e mettere ω_i questo stesso valore per ogni $i \in C$

Esercizio 3. Verificare che questa dinamica è anche irriducibile ed aperiodica. (Consiglio: cominciare con l'osservazione che la probabilità di passare da ω ad ω^x in un passo di tempo è sempre maggiore di zero.)

Allora, $\pi_{\Lambda; \beta, 0}^\emptyset$ è l'unica misura stazionaria di questa dinamica.

Dalla forma scritta appena sopra è anche evidente che niente dipende di E , e quindi ω da solo - i spin - sono da parte una catena di Markov, che per forza ha $\mu_{\Lambda; \beta, 0}^\emptyset$ come unica misura stazionaria, essendo questo il marginale di $\pi_{\Lambda; \beta, 0}^\emptyset$. La dinamica considerato in questo modo si chiama *algoritmo di Swendsen e Wang*.

4 L'algoritmo di Wolff

C'è un'alternativa più efficiente, ed anche un po' più facile da programmare: l'algoritmo di Wolff. Formalmente, questo è diverso solo in quanto nel secondo passo, invece di scegliere nuovi valori di spin per tutti i cluster, di scegliere uniformemente un sito x , e poi cambiare i valori di ω_y per tutti gli y nello stesso cluster di x ; questo nuovo secondo passo è una forma di dinamica di Metropolis per la distribuzione congiunta π , e quindi abbiamo sempre equilibrio in dettaglio per π .

Ancora meglio, pensando di nuovo solo della distribuzione di ω , si può ottenere la stessa probabilità di transizione con un algoritmo che costruisce, non tutti i cluster, ma solo uno, cioè il seguente (l'algoritmo di Wolff propriamente detto):

1. Genera uniformemente un $x \in \Lambda$

2. Cominciando coi insiemi $X = C = \{x\}$, procedere iterativamente ripetendo le operazioni seguente finché X non diventa vuoto:
 - (a) Toglie un elemento y (scelta arbitrariamente) da X
 - (b) Per ogni $z \in \Lambda \setminus C$ tale che $\{y, z\} \in \mathcal{E}_\Lambda$ e $\omega_y = \omega_z$, decide indipendentemente fra:
 - i. Con probabilità p_β , aggiungere z a sia X sia C
 - ii. Con probabilità $1 - p_\beta$, non fare niente
3. Per ogni $w \in C$, cambia ω_w in $-\omega_w$.

Questo ha il vantaggio, fra l'altro, di essere più semplice da specificare (e quindi da scrivere) rispetto un algoritmo che costruisce tutti gli cluster.

Esercizio 4. Verificare che la legge di C , dato un certo ω e x è lo stesso che quello del cluster di E che contiene x generato in corso dell'algoritmo di Swendsen e Wang.

L'algoritmo di Wolff converge in modo molto rapido per $\beta \leq \beta_c$;

Esercizio 5. Creare un programma che, partendo da una configurazione iniziale $\bar{\omega} = 1$, implementa l'algoritmo di Wolff T volte per una regione $L \times L$ in due dimensione per $\beta = \beta_c = \tanh^{-1}(\sqrt{2} - 1)$, e produce un grafico di m_Λ^2 come funzione del tempo τ , e una visualizzazione della configurazione finale.

Per verificare l'esito, eseguire il programma con $T = 100$, $L = 128$.




Figura 2: Esempio del risultato in Esercizio 5

Figura 2 presenta un esempio del risultato dell'esercizio per referencia; la visualizzazione della configurazione può essere realizzato comodamente con `matplotlib.pyplot.imshow`.